

五个班级学业成绩的数据挖掘与分析

——基于 KDD 流程的数据预处理、统计描述与聚类分析

课程名称：人工智能（第二章 数据挖掘）

作业题目：作业一 五个班级成绩数据挖掘与分析

姓 名：_____

学 号：_____

学 院：_____

提交日期：2026 年 10 月

摘 要

本文以五个班级 178 名学生的学期成绩汇总数据为对象，按照知识发现（KDD）流程进行数据挖掘与分析。预处理阶段审查了数据质量，处理了数值以文本存储、通过率记录格式不统一以及修读门数不同导致总分不可比等问题，并构造课程平均分，进行 Min-Max 归一化与 Z-score 标准化。分析阶段对各班成绩进行描述性统计与可视化（直方图、箱线图、Q-Q 图、平行坐标图），以单因素方差分析和 Kruskal-Wallis 检验比较班级差异，以主成分分析和 K-means 聚类识别学生群体。五个班级的学分加权平均分差异显著（ $H = 63.28$ ， $p < 0.001$ ， $\epsilon^2 = 0.34$ ），均值由高到低依次为 BD、T1、T2、D2 与 D1；BD 班均值最高、标准差最小；D1 班不及格率为 40.0%，不及格门次占五个班级总数的 55%；同一培养方案的平行班之间差异不显著。K-means 聚类将学生分为学业优良、中等与学业预警三类，其中学业预警学生 22 名。

关键词：数据挖掘；数据预处理；描述性统计；箱线图；K-means 聚类；学业预警

1 引言

高校教学管理积累了大量学生成绩数据。成绩汇总表逐行记录每名学生的学业指标，直接阅读难以看出班级间差异、成绩分布特征和需要关注的学生。数据挖掘是从大量数据中提取隐含的、先前未知的、潜在有用的模式的过程，适用于此类问题。

本文以五个班级同一学期的成绩汇总数据为对象，依据 KDD 流程完成数据预处理、统计描述、可视化分析与数据挖掘。具体工作包括：评估原始数据质量，经清洗、集成与变换形成分析数据集；比较各班成绩的集中趋势与离散趋势，并检验班级差异的显著性；识别成绩离群的个体，并以聚类方法划分学生群体。

2 数据来源与变量说明

数据来自课程提供的 Excel 文件，含 5 个工作表，分别对应 D1、D2、BD、T1、T2 五个班级，合计 178 条学生记录，每条记录 10 个字段。每条记录为一个数据对象，每个字段为一个属性。各字段的定义及属性类型见表 1，其中班级与成绩等级为预处理中构造的衍生属性。

表 1 变量定义与属性类型

变量	定义	属性类型
ID	学生编号 (BD 表中列名为“姓名”)	标称属性
学分加权平均分	$\Sigma(\text{课程成绩} \times \text{学分}) / \Sigma \text{学分}$, 百分制	数值属性 (连续)
获得学分	本学期已获得的学分	数值属性 (离散)
不及格学分	不及格课程对应的学分	数值属性 (离散)
总学分	本学期应修学分	数值属性 (离散)
不及格门次	不及格课程的门数	数值属性 (离散)
平均学分绩点	GPA	数值属性 (连续)
通过率	获得学分/总学分	数值属性 (连续)
门数	本学期修读课程门数	数值属性 (离散)
总分	各门课程成绩之和	数值属性 (连续)
班级	数据来源工作表 (衍生)	标称属性
成绩等级	按学分加权平均分离散化 (衍生)	序数属性

3 数据预处理

预处理依次进行数据清洗、数据集成、数据变换与数据规约。

3.1 数据质量审查

从准确性、完整性和一致性三方面审查五个工作表，结果见表 2。

表 2 各工作表数据质量审查结果

审查项目	D1	D2	BD	T1	T2
记录数	35	34	30	40	39
以文本格式存储的数值单元格数	314	306	0	360	0
首列列名	ID	ID	姓名	ID	ID
学号示例	D11	21D211	21BD1	21T111	21T211
通过率记录格式	文本(%)	文本(%)	数值	文本(%)	数值
缺失值	0	0	0	0	0
重复学号/重复记录	0/0	0/0	0/0	0/0	0/0
越界值	0	0	0	0	0
违反“获得学分+不及格学分=总学分”	0	0	0	0	0
违反“通过率=获得学分/总学分”	0	0	0	0	0
应修学分/课程门数（众数）	28/11	28/11	27/11	25/10	25/10
修读门数低于本班标准的人数	1	2	2	1	2

注：越界值指学分加权平均分不在[0, 100]、平均学分绩点不在[0, 5]或通过率不在[0, 1]内的取值；“文本(%)”指形如“82.14%”的文本，“数值”指数值型小数。

原始数据无缺失值、重复记录和越界值，全部记录均满足两项业务规则（获得学分+不及格学分=总学分；通过率=获得学分/总学分），准确性与完整性符合要求。一致性方面存在三类问题：D1、D2、T1 三个工作表的数值几乎全部以文本格式存储，无法直接计算；记录格式不统一，D1、D2、T1 三班的通过率为带百分号的文本，BD 与 T2 两班为数值型小数，BD 表首列列名为“姓名”而其余各表为“ID”，D1 班学号缺少“21”前缀；各班应修学分与课程门数不同，D 类班级为 28 学分、11 门，BD 班为 27 学分、11 门，T 类班级为 25 学分、10 门，另有 8 名学生的修读门数低于本班标准，因此总分在班级之间和学生之间不可比。

3.2 数据清洗

以文本存储的数值统一转换为数值型（Python 中使用 `pd.to_numeric`，Excel 中可用“转换为数字”功能）；通过率去除百分号，统一换算为 0~1 之间的小数；BD 表首列列名统一为“ID”。成绩明显偏低的记录予以保留，在 4.5 节中按箱线图规则识别为离群点。

3.3 数据集成

将五个工作表纵向合并为一张 178 条记录的总表，并增设班级字段标识数据来源。实体识别以学号为唯一标识，合并后 178 个学号互不重复，D1 班学号虽缺少前缀，但与其他班级无冲突；冗余属性通过相关分析检测（见 3.5 节）；两项业务规则的交叉校验未发现数据值冲突。

3.4 数据变换

数据变换包括四项。课程平均分定义为总分与修读门数之比。总分受修读门数影响较大，如 21BD1 仅修读 10 门课程，总分 931 分在 BD 班排名靠后，课程平均分 93.1 分却为该班最高。全体样本中，总分与学分加权平均分的 Pearson 相关系数为 0.66，课程平均分与学分加权平均分的相关系数为 0.97，故跨班比较不使用总分。Min-Max 归一化 $x' = (x - \min)/(\max - \min)$ 将各指标映射至 [0, 1] 区间，用于平行坐标图。Z-score 标准化 $z = (x - \mu)/\sigma$ 用于主成分分析与 K-means 聚类，班内 Z 分数用于衡量学生在本班的相对位置。按学分加权平均分将成绩离散化为优秀 [85, 100]、良好 [80, 85)、中等 [70, 80) 与及格 [60, 70) 四个等级，得到序数属性成绩等级。

3.5 数据规约




图 1 各数值属性的 Pearson 相关系数矩阵 (N = 178)

各数值属性间的 Pearson 相关系数见图 1。学分加权平均分与平均学分绩点、课程平均分的相关系数分别为 0.99 和 0.97，三者近乎线性相关；通过率与不及格学分的相关系数为 -1.00，二者满足通过率 = 1 - 不及格学分 / 总学分。属性间存在明显冗余，因此描述性统计以学分加权平均分衡量学业水平，以不及格门次和不及格率衡量学业风险；第 6 节用主成分分析将 6 项指标降为 2 个主成分（累计方差贡献率 98.3%）。

4 描述性统计分析

4.1 集中趋势与离散趋势

集中趋势以均值、中位数和众数度量，离散趋势以极差、方差、标准差、四分位距和变异系数度量，各班学分加权平均分的统计结果见表 3。

表 3 各班学分加权平均分的描述性统计

统计量	D1	D2	BD	T1	T2	全体
样本量	35	34	30	40	39	178
均值	77.15	78.90	87.67	81.95	81.16	81.21
中位数	77.18	78.65	87.93	81.66	81.96	81.37
众数	75.64/81.29	无	91.26	81.92	83.04/85.84	—
最小值	61.93	65.07	80.59	70.16	67.68	61.93
最大值	86.46	89.39	92.19	90.12	91.00	92.19
极差	24.53	24.32	11.60	19.96	23.32	30.26
下四分位数 Q1	74.66	76.24	85.94	79.17	78.22	77.18
上四分位数 Q3	81.29	82.28	90.09	85.47	84.43	85.74
四分位距 IQR	6.63	6.04	4.16	6.30	6.21	8.56
方差	26.99	29.64	9.90	18.73	25.43	33.41
标准差	5.20	5.44	3.15	4.33	5.04	5.78
变异系数	6.7%	6.9%	3.6%	5.3%	6.2%	7.1%
偏度	-0.70	0.00	-0.66	-0.24	-0.71	-0.40
峰度	1.04	0.22	0.04	0.09	0.64	0.08

注：方差与标准差的分母为 $n-1$ ；众数栏“无”表示各取值均只出现一次，列出两个值表示存在两个众数；数值按四舍五入保留两位小数。

BD 班的均值（87.67）与中位数（87.93）均明显高于其他班级，较全体均值高约 6.5 分；T1 班与 T2 班接近全体平均水平；D2 班与 D1 班低于全体平均水平，D1 班均值最低（77.15）。离散程度方面，BD 班标准差为 3.15，变异系数为 3.6%，成绩最为集中；D2 班与 D1 班的标准差分别为 5.44 和 5.20，极差均超过 24 分。偏度方面，D1、BD 与 T2 三个班级约为 -0.7，呈左偏分布，均值低于中位数，少数低分学生拉低了班级均值；D2 班的偏度为 0.00，分布对称。

4.2 班级均值比较




图2 各班学分加权平均分均值（误差线为95%置信区间，虚线为全体均值）

BD班均值的95%置信区间与其余四个班级均不重叠；T1与T2、D1与D2的置信区间分别大幅重叠（图2），检验结果见第5节。

4.3 成绩分布形态




图3 各班学分加权平均分分布直方图（组距2.5分；实线为均值，虚线为中位数）

BD班成绩全部高于80分，集中于85~92分（图3）；T1班与T2班的成绩主体位于77~87分；D1班与D2班的成绩主体位于72~82分，并在70分以下存在左侧拖尾。

4.4 成绩等级构成




图 4 各班成绩等级构成

各班成绩等级构成见图 4 与表 4。BD 班优秀率为 86.7%（26/30），其余学生均为良好；T1 班与 T2 班良好及以上等级的比例分别为 67.5%与 66.7%；D1 班与 D2 班以中等为主，占比分别为 62.9%与 58.8%，D1 班仅 1 人达到优秀。

表 4 各班成绩等级人数分布

班级	优秀	良好	中等	及格	合计
D1	1	10	22	2	35
D2	5	8	20	1	34
BD	26	4	0	0	30
T1	12	15	13	0	40
T2	9	17	11	2	39

4.5 箱线图与离群点检测

离群点按箱线图规则判定，即落在 $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ 以外的观测值。




图5 各班学分加权平均分箱线图（空心圆为离群点）

BD 班箱体位置最高、高度最小（图 5），其最低分（80.59）高于 D1 班与 D2 班的中位数；T1 班与 T2 班的中位数接近（81.66 与 81.96），T2 班在低分端有两个离群点。五个班级共识别出 4 个离群点，均在低分一侧，见表 5。

表 5 箱线图规则识别出的离群学生

班级	学号	加权平均分	平均绩点	不及格门次	不及格学分	通过率	班内 Z 分数
D1	D45	61.93	1.43	4	11	60.7%	-2.93
D2	21D244	65.07	1.68	3	13	53.6%	-2.54
T2	21T248	67.68	1.76	2	10	60.0%	-2.67
T2	21T249	68.84	1.62	3	11	56.0%	-2.44

注：加权平均分即学分加权平均分，平均绩点即平均学分绩点，下同。

这 4 名学生均有 2~4 门课程不及格，学分通过率为 53.6%~60.7%，班内 Z 分数均低于 -2.4，即成绩低于本班均值 2.4 个标准差以上。

4.6 不及格情况




图 6 各班不及格率（至少一门课程不及格的学生占比）

本文将至少一门课程不及格的学生占全班人数的比例称为不及格率。全体样本中有 24 名学生存在不及格课程，累计 38 门次（图 6）。D1 班不及格率为 40.0%（14/35），不及格门次为 21，占全部不及格门次的 55%；BD 班无学生不及格，T1 班仅 1 名学生有 1 门课程不及格。D2 班与 T2 班的均值相差约 2.3 分，不及格率则相近（14.7%与 10.3%）。各班其他学业指标见表 6。

表 6 各班其他学业指标

班级	平均绩点	课程平均分	不及格人数	不及格率	不及格门次	人均不及格学分	平均通过率
D1	2.57	81.20	14	40.0%	21	2.34	91.5%
D2	2.71	82.57	5	14.7%	8	1.12	96.0%
BD	3.61	88.70	0	0.0%	0	0.00	100.0%
T1	3.02	84.57	1	2.5%	1	0.13	99.5%
T2	2.95	83.72	4	10.3%	8	0.82	96.7%

4.7 班级成绩分布的 Q-Q 图比较

Q-Q 图以两个班级相同分位数上的成绩为坐标绘点，点位于直线 $y = x$ 上方表示纵轴班级在该分位数上的成绩更高。




图 7 班级间学分加权平均分的 Q-Q 图

D1 与 D2 相比（图 7 左），各点总体位于 $y = x$ 上方，D2 在大多数分位数上高出 D1 约 1~1.5 分，两端（尤其是高分端）差距更大。T1 与 T2 相比，中间分位数的点基本贴合 $y = x$ ，两班中等水平学生的成绩相近；最低分位数的点明显位于直线下方，T2 班的相对劣势集中于少数低分学生，即图 5 中的两个离群点。BD 与 T1 相比，全部点位于 $y = x$ 上方，低分位与中分位相差约 6~7 分，高分端缩小至 3~4 分，拟合斜率小于 1，BD 班在各分位数上均高于 T1 班且分布更集中。

4.8 多指标的平行坐标分析




图 8 五个班级多指标均值的平行坐标图（Min-Max 归一化）

图 8 将各班 6 项指标的均值经 Min-Max 归一化后以折线连接。BD 班在成绩类指标上均为最高，在不及格类指标上均为最低，D1 班与之相反。T1 班的通过率与不及格类指标接近 BD 班，成绩类指标居中，即不及格少而高分学生比例不高；D2 班与 T2 班的不及格类指标居中。

5 班级差异的显著性检验

Shapiro-Wilk 检验的 p 值均大于 0.05（最小为 0.105），以中位数为中心的 Levene 检验（Brown-Forsythe 检验） $p = 0.155$ ，满足正态性与方差齐性假设。单因素方差分析结果为 $F = 22.68$ ， $p < 0.001$ ；非参数 Kruskal-Wallis 检验结果为 $H = 63.28$ ， $p < 0.001$ ， $\varepsilon^2 = 0.34$ （大效应）。五个班级的学分加权平均分存在显著差异。

两两比较采用 Mann-Whitney U 检验， p 值经 Holm 法校正，结果见表 7。

表 7 班级两两比较结果

比较组	中位数差	原始 p 值	Holm 校正 p 值	显著性
D1 与 BD	-10.75	1.53×10^{-10}	1.53×10^{-9}	显著
D2 与 BD	-9.28	2.10×10^{-8}	1.89×10^{-7}	显著
BD 与 T2	+5.97	7.42×10^{-8}	5.94×10^{-7}	显著
BD 与 T1	+6.27	4.29×10^{-7}	3.00×10^{-6}	显著
D1 与 T1	-4.48	9.51×10^{-5}	5.70×10^{-4}	显著
D1 与 T2	-4.78	8.21×10^{-4}	0.004	显著
D2 与 T1	-3.02	0.008	0.033	显著
D2 与 T2	-3.32	0.048	0.143	不显著
D1 与 D2	-1.47	0.267	0.534	不显著
T1 与 T2	-0.30	0.670	0.670	不显著

注：中位数差为前一班级减去后一班级的中位数；显著性水平 $\alpha = 0.05$ ；按原始 p 值升序排列。

BD 班与其余四个班级的差异均显著；D1 与 T1、D1 与 T2、D2 与 T1 的差异亦显著；D1 与 D2、T1 与 T2 两组平行班差异不显著，D2 与 T2 的差异经校正后不显著。成绩差异主要存在于不同培养方案之间，同一培养方案的平行班之间差异不显著。

6 学生群体的聚类分析

第 4、5 节以班级为单位比较，本节不预设分组，用聚类方法识别学生群体。

6.1 主成分分析

选取学分加权平均分、平均学分绩点、课程平均分、不及格门次、不及格学分与通过率 6 项指标，经 Z-score 标准化后进行主成分分析。第一主成分的方差贡献率为 80.5%，6 项指标的载荷绝对值均约为 0.41，其中学分加权平均分、平均学分绩点、课程平均分与通过率为正，不及格门次与不及格学分为负，可解释为综合学业水平。第

二主成分的方差贡献率为 17.8%，其载荷中成绩类指标与不及格门次、不及格学分同号，通过率异号，反映成绩高低与不及格程度之间的不一致。前两个主成分的累计方差贡献率为 98.3%。

6.2 K-means 聚类

在标准化后的六维数据上运行 K-means 算法，每个 k 值重复运行 500 次（随机初始化与 k-means++ 初始化交替），取簇内误差平方和（SSE）最小的结果； k 值依据肘部法与轮廓系数确定。




图 9 不同聚类数 k 下的簇内误差平方和（左）与轮廓系数（右）

$k = 2$ 时轮廓系数最高（0.68），但划分结果与是否存在不及格课程基本一致（仅 1 名有不及格课程的学生归入另一类），仅凭不及格门次即可得到。 $k = 3$ 时 SSE 曲线出现拐点（由 439 降至 234），轮廓系数为 0.52，并将其余学生进一步分为高分与中等两类。 $k = 4$ 时轮廓系数为 0.55，略高于 $k = 3$ ，新增的划分是将 $k = 3$ 时的学业预警组拆分为 8 人（不及格 2~4 门）与 15 人（不及格 1~2 门）两类。鉴于预警组规模较小，其内部差异可由表 9 的排序反映，故取 $k = 3$ （图 9）。




图 10 K-means 聚类结果在前两个主成分上的投影 ($k=3$)

在前两个主成分平面上（图 10），没有不及格课程的学生（A 组全部及 B 组绝大多数）近似分布于一条直线，其差别主要在分数高低；C 组学生以及 B 组中 2 名各有 1 门课程不及格的学生偏离该直线，分布于左侧，反映了平均分之外的不及格信息。三个聚类的特征见表 8。

表 8 三个聚类的特征（各指标均值）

聚类	人数	加权平均分	平均绩点	不及格门次	不及格学分	通过率
A 组（学业优良组）	73	86.68	3.50	0.00	0.00	100.0%
B 组（中等组）	83	78.94	2.72	0.02	0.05	99.8%
C 组（学业预警组）	22	71.65	2.05	1.64	6.95	74.3%

A 组 73 人，学分加权平均分均值 86.68（82.32~92.19），无人不及格，命名为学业优良组；B 组 83 人，人数最多，均值 78.94，仅 2 人各有 1 门课程不及格，命名为中等组；C 组 22 人，均值 71.65，人均不及格 1.64 门次，平均通过率 74.3%，命名为学业预警组。




图 11 各班学生在三个聚类中的分布

BD 班 30 名学生中 27 人属于学业优良组，无学业预警学生（图 11）；D1 班有 12 人属于学业预警组，占该班人数的 34%、全部预警学生的 55%；T1 班与 T2 班学业优良组均为 17 人，学业预警组分别为 1 人和 4 人。




图 12 不及格门次与学分加权平均分的散点图（按聚类着色， $r = -0.64$ ）

不及格门次与学分加权平均分呈中度负相关（ $r = -0.64$ ），聚类边界与是否存在不及格课程及 82~83 分附近的分数线基本一致（图 12）。

6.3 学业预警名单

学业预警组（C 组）名单按学分加权平均分升序列于表 9，其中 D45、21D244、21T248、21T249 同时为箱线图离群点，预警级别最高。

表 9 学业预警学生名单

序号	班级	学号	加权平均分	平均绩点	不及格门次	不及格学分	通过率
1	D1	D45	61.93	1.43	4	11	60.7%
2	D2	21D244	65.07	1.68	3	13	53.6%
3	D1	D44	66.71	1.88	2	10	64.3%
4	T2	21T248	67.68	1.76	2	10	60.0%
5	T2	21T249	68.84	1.62	3	11	56.0%
6	D1	D42	70.00	1.96	1	5	82.1%
7	D1	D43	70.04	2.02	2	10	64.3%
8	T1	21T150	70.16	1.82	1	5	80.0%
9	D2	21D242	71.14	2.00	1	5	82.1%
10	D2	21D241	72.43	2.02	1	5	82.1%
11	D1	D40	72.68	2.11	1	3	89.3%
12	D2	21D239	72.82	2.02	2	10	64.3%
13	D2	21D240	73.00	2.18	1	5	82.1%
14	D1	D41	73.11	2.13	2	6	78.6%
15	D1	D31	73.54	2.20	2	10	64.3%
16	D1	D39	73.61	2.14	1	3	89.3%
17	T2	21T247	73.80	2.14	2	6	76.0%
18	D1	D34	74.64	2.25	1	5	82.1%
19	D1	D26	75.58	2.38	1	5	79.2%
20	D1	D30	75.64	2.41	1	5	82.1%
21	T2	21T237	76.16	2.38	1	5	80.0%
22	D1	D25	77.64	2.54	1	5	82.1%

7 结论与建议

7.1 研究结论

原始数据完整、无重复记录且满足业务规则，但存在数值以文本存储、记录格式不统一和总分不可比等问题，经清洗、集成与变换后形成 178×23 的分析数据集，跨班比较以学分加权平均分代替总分。五个班级的成绩存在显著差异（ $p < 0.001$ ，大效应），均值由高到低依次为 BD、T1、T2、D2 与 D1；BD 班均值最高、标准差最小，优秀率 86.7%，无学生不及格。学业风险集中于 D1 班：该班不及格率为 40.0%，不及格门次与学业预警人数均占全体的 55%。同一培养方案的平行班之间差异不显著，班级差异主要来自不同培养方案之间，T2 班的相对劣势集中于少数低分学生。聚类将学生分为学业优良（73 人）、中等（83 人）与学业预警（22 人）三类，是否存在不及格课程是区分学业预警群体的主要特征。

7.2 对策建议

对学业预警组的 22 名学生，尤其是 4 名离群学生，开展个别学业指导并制定补考与重修计划；对中等组学生，可将学分加权平均分达到约 82 分（学业优良组与中等组的分界）作为提升目标。D1 班需调取课程层面的成绩明细，找出不及格集中的课

程，再判断原因在于课程难度、教学安排还是学习投入。上述预处理与聚类流程可在每学期末重复运行，用于更新学业预警名单。

7.3 研究局限

D 类、BD 与 T 类班级的课程与评分教师可能不同，跨培养方案的平均分比较包含课程难度与评分尺度的影响。数据只有学期汇总指标，无法定位不及格课程，也无法查明 8 名学生修读门数偏少的原因。各班样本量为 30~40 人，且只有一个学期，聚类结果与预警名单未经跨学期检验。

8 分析工具与人工智能使用说明

数据处理与统计分析使用 Python 3 完成，程序库包括 pandas（数据处理）、SciPy（统计检验）、NumPy（主成分分析与 K-means）与 Matplotlib（绘图）。按课程人工智能使用规范的要求说明如下：本文的分析代码和正文初稿由 Anthropic 公司的 Claude 辅助生成，文中统计结果均由该代码在原始数据上运行得到。

【提交前请本人如实填写：本人完成的工作，例如在本地运行代码并以 Excel“数据分析—描述统计”功能复核表 3 的结果、对正文所作的修改与补充等】