

五个班级学业成绩数据挖掘与分析报告

——基于 KDD 流程的数据预处理、描述性统计、可视化与聚类分析

课 程：人工智能（第二章 数据挖掘）

作 业：作业一：五个班级成绩数据挖掘与分析

姓 名：_____

学 号：_____

学 院：_____

日 期：2026 年 10 月

摘要

本报告以课堂提供的 D1、D2、BD、T1、T2 五个班级共 178 名学生的成绩数据为对象，按照数据挖掘的 KDD 流程（领域理解 → 数据采集 → 数据预处理 → 数据挖掘 → 评估 → 知识表示）开展分析。在预处理阶段完成了文本型数值转换、通过率格式统一、列名统一、缺失/重复/越界/逻辑一致性检查、五表集成，以及“课程平均分”构造、Min-Max 与 Z-score 标准化等数据变换；在分析阶段从集中趋势与离散趋势两方面进行描述性统计，绘制直方图、箱线图、Q-Q 图、平行坐标图等，并进一步使用显著性检验、相关分析、主成分分析（PCA）与 K-means 聚类挖掘学生群体结构。

主要发现：① 五个班成绩差异显著（Kruskal-Wallis $H = 63.28$ ， $p < 0.001$ ，效应量 $\epsilon^2 = 0.34$ ），由高到低依次为 BD (87.67) > T1 (81.95) > T2 (81.16) > D2 (78.90) > D1 (77.15)；② BD 班均值最高且离散程度最小（变异系数 3.6%），87% 学生达到优秀，无人挂科；③ D1 班挂科问题最突出，挂科率 40.0%，不及格门次占五个班总数的 55%；④ 同一培养方案下的平行班（D1 与 D2、T1 与 T2）之间差异不显著；⑤ 聚类将学生分为“学业优良”“稳定中等”“学业预警”三类，识别出 22 名学业预警学生，其中 12 人来自 D1 班。

关键词：数据挖掘；数据预处理；描述性统计；箱线图；K-means 聚类；学业预警

一、问题背景与分析目标

在教育管理中，教务部门每学期都会产生大量成绩数据，但原始成绩表往往只是“一行一个学生”的数字罗列，难以直接看出班级之间的差距、成绩分布形态以及需要重点关注的学生。数据挖掘的任务正是从这些数据中提炼出隐含的、有用的知识（Data → Information → Knowledge → Wisdom）。

本次分析的数据为五个班级同一学期的成绩汇总表。分析目标如下：

- 目标 1 数据质量：检查数据是否存在缺失值、重复值、异常值、格式不一致等问题，并完成清洗、集成与变换，得到可直接建模的高质量数据；
- 目标 2 整体比较：从集中趋势和离散趋势两个角度描述并比较五个班的成绩概况，判断差异是否具有统计显著性；
- 目标 3 结构挖掘：识别成绩异常的个体，发现学生群体的内在分类结构，为学业预警和教学改进提供依据。

二、数据说明

数据来源为课堂发放的 Excel 文件，含 5 个工作表，每个工作表对应一个班级，共 178 条学生记录、10 个字段。按照数据对象与属性的概念：每一行是一个数据对象（学生），每一列是一个属性（又称维度、特征、变量）。字段说明及属性类型见表 1。

表 1 字段说明与属性类型

字段	含义	属性类型
ID (BD 表为“姓名”)	学生编号	标称属性（唯一标识）
学分加权平均分	$\Sigma(\text{课程成绩} \times \text{学分}) / \Sigma \text{学分}$ ，百分制	数值属性（比率标度）
获得学分 / 不及格学分 / 总学分	已获得、未获得及应修学分	数值属性（离散）
不及格门次	不及格课程门数	数值属性（离散）
平均学分绩点	GPA，0-5 分制	数值属性（连续）
通过率	获得学分 / 总学分	数值属性（比率）
门数	本学期修读课程门数	数值属性（离散）
总分	各门课程成绩之和	数值属性（连续）
成绩等级（衍生）	由加权平均分离散化得到	序数属性（有序）
班级（衍生）	数据来源工作表	标称属性

三、数据预处理

“垃圾进，垃圾出（Garbage in, garbage out）”。在建模之前，本文按照数据清洗、数据集成、数据变换、数据规约四个任务对原始数据进行预处理。

3.1 数据质量审查

首先对五个工作表逐一进行数据质量审查，审查内容涵盖准确性、完整性、一致性三个维度，结果见表 2。

表 2 五个工作表的数据质量审查结果

检查项	D1	D2	BD	T1	T2
记录数	35	34	30	40	39
以文本格式存储的数值单元格	314	306	0	360	0
首列列名	ID	ID	姓名	ID	ID
学号格式示例	D11	21D211	21BD1	21T111	21T211
通过率存储格式	百分号	百分号	小数	百分号	小数
缺失值	0	0	0	0	0
重复学号 / 重复记录	0 / 0	0 / 0	0 / 0	0 / 0	0 / 0
越界值 (分数 $\notin[0,100]$ 、GPA $\notin[0,5]$ 、通过率 $\notin[0,1]$)	0	0	0	0	0
获得学分+不及格学分 $\neq$ 总学分	0	0	0	0	0
通过率 $\neq$ 获得学分/总学分	0	0	0	0	0
应修学分 / 门数 (众数)	28 / 11	28 / 11	27 / 11	25 / 10	25 / 10
修读门数少于本班标准的人数	1	2	2	1	2

审查结论：数据不存在缺失值、重复记录和越界值，且“获得学分 + 不及格学分 = 总学分”“通过率 = 获得学分/总学分”两条业务规则在全部记录上均成立，说明数据的准确性与完整性良好。但存在以下一致性问题，必须在分析前处理：

- 数值以文本存储：D1、D2、T1 三个表的数值几乎全部以文本格式保存（Excel 单元格左上角带绿色小三角），直接计算会报错或被忽略；
- 格式不统一：D1、D2、T1 的通过率为“82.14%”形式的文本，BD、T2 为“0.8”形式的小数；BD 表首列列名为“姓名”，其余为“ID”；D1 学号缺少“21”前缀（如 D11），与其他班（如 21D211）编码规则不同；
- 量纲不一致：D 类班级应修 28 学分/11 门，BD 为 27 学分/11 门，T 类为 25 学分/10 门，另有 8 名学生修读门数少于本班标准。因此“总分”随修读门数变化，不同班级、不同学生之间不可直接比较。

3.2 数据清洗

针对上述问题，执行以下清洗操作：

- 类型转换：将所有数值字段由文本转换为数值型（Excel 中可选中区域 → 点击绿色感叹号 → “转换为数字”；Python 中使用 `pd.to_numeric`）；
- 格式统一：去除通过率中的“%”并统一为 0–1 的小数；将 BD 表首列统一更名为“ID”；
- 缺失值与噪声：经检查无缺失值，无需删除或填充；对于成绩偏低的个体，不将其视为录入错误，而是保留下来在 4.5 节用箱线图规则做离群点分析——因为对教学管理而言，这些“异常”学生恰恰是最需要关注的对象，不能简单平滑掉。

3.3 数据集成

五个班的数据分散在五个工作表中，为便于整体比较，将其纵向合并为一张 178 行的总表，并新增“班级”字段记录数据来源。集成时需关注三类问题：① 实体识别——以学号作为唯一标识（而非姓名，以免重名），经检查合并后 178 个学号无重复，D1 学号虽缺少前缀但不与其他班冲突；② 冗余——属性间的冗余用相关分析检测（见 3.5 节）；③ 数据值冲突——通过两条业务规则的交叉校验，未发现取值冲突。

3.4 数据变换


为消除量纲差异、便于比较和建模，进行了以下变换：

- 构造“课程平均分” = 总分 / 门数。原始“总分”受修读门数影响：例如 21BD1 只修了 10 门，总分 931 在 BD 班排名靠后，但其课程平均分 93.1 实际为全班最高。全体样本中，总分与加权平均分的 Spearman 秩相关系数仅 0.61，而课程平均分与加权平均分的相关系数达 0.97。因此后续分析不使用总分做跨班比较；
- Min-Max 归一化： $x' = (x - \min) / (\max - \min)$ ，将数据映射到 $[0, 1]$ ，用于平行坐标图（图 8）中不同量纲指标的同图比较；
- Z-score 标准化： $z = (x - \mu) / \sigma$ ，用于 PCA 与 K-means 聚类（消除量纲对距离计算的影响），以及计算“班内 Z 分数”衡量学生在本班的相对位置；
- 离散化：将学分加权平均分划分为四个等级——优秀（ ≥ 85 ）、良好（80–85）、中等（70–80）、及格（60–70），得到序数属性“成绩等级”。

3.5 数据规约

计算各数值属性两两之间的 Pearson 相关系数（图 6），用于检测冗余属性：

图6 各数值属性相关系数矩阵（全体178人）



可以看到：学分加权平均分与平均学分绩点（ $r = 0.99$ ）、课程平均分（ $r = 0.97$ ）几乎完全线性相关；通过率与不及格学分的相关系数为 -1.00 （二者存在确定的函数关系：通过率 = $1 - \text{不及格学分} / \text{总学分}$ ）。这说明属性间存在明显冗余。据此进行维规约：在描述性统计中以“学分加权平均分”作为衡量学习成绩的核心指标，以“不及格门次/挂科率”作为衡量学业风险的补充指标；在第六部分进一步用 PCA 将 6 个指标压缩为 2 个主成分（累计解释方差 98.3%）。

四、描述性统计分析可视化

4.1 集中趋势与离散趋势

描述性统计从两个方面刻画数据：集中趋势（均值、中位数、众数）反映成绩的“平均水平”；离散趋势（极差、方差、标准差、四分位距、变异系数）反映成绩的“差异程度”。各班学分加权平均分的统计量见表 3。

表 3 各班学分加权平均分描述性统计

统计量	D1	D2	BD	T1	T2	全体
样本数	35	34	30	40	39	178
均值	77.15	78.90	87.67	81.95	81.16	81.21
中位数	77.18	78.65	87.92	81.66	81.96	81.37
众数	75.64、81.2 9	无（各值不 重复）	91.26	81.92	83.04、85.8 4	—
最小值	61.93	65.07	80.59	70.16	67.68	61.93
最大值	86.46	89.39	92.19	90.12	91.00	92.19
极差	24.53	24.32	11.60	19.96	23.32	30.26
Q1（25%分位数）	74.66	76.24	85.94	79.17	78.22	77.18
Q3（75%分位数）	81.29	82.27	90.09	85.47	84.43	85.74
IQR（四分位距）	6.63	6.04	4.16	6.30	6.21	8.56
方差	26.99	29.64	9.90	18.73	25.43	33.41
标准差	5.20	5.44	3.15	4.33	5.04	5.78
变异系数	6.7%	6.9%	3.6%	5.3%	6.2%	7.1%
偏度	-0.70	0.00	-0.66	-0.24	-0.71	-0.40
峰度	1.04	0.22	0.04	0.09	0.64	0.08

注：方差、标准差为样本统计量（分母 $n-1$ ），与 Excel“数据分析→描述统计”的结果口径一致；众数在连续型成绩数据中意义有限（多数取值仅出现一次），仅作参考。

集中趋势：BD 班的均值（87.67）和中位数（87.92）都明显高于其他各班，比全体均值高约 6.5 分；T1、T2 接近全体平均水平；D2、D1 低于平均水平，D1 最低（77.15）。

离散趋势：BD 班标准差仅 3.15、变异系数 3.6%，是成绩最集中、两极分化最小的班；D2（标准差 5.44）与 D1（5.20）离散程度最大，极差均超过 24 分，班内差距较大。

分布形态：D1、BD、T2 的偏度为负（约 -0.7），均值低于中位数，呈“左偏”——多数学生成绩集中在中高区间，少数低分学生拉低了均值；D2 偏度接近 0，基本对称。这也说明在比较存在少数极端值的班级时，中位数比均值更稳健。

4.2 各班平均水平对比





图 1 在柱状图上叠加了 95% 置信区间误差线。BD 班的置信区间与其他四个班完全不重叠，领先优势稳健；T1 与 T2 的区间高度重叠，D1 与 D2 的区间也高度重叠，初步说明平行班之间差异不大（第五部分用检验加以确认）。


4.3 成绩分布形态

图2 各班学分加权平均分分布直方图（实线=均值，虚线=中位数，组距2.5分）



直方图反映了各班成绩的频数分布。BD 班成绩全部位于 80 分以上，并集中在 85-92 分；T1、T2 的主体集中在 77-87 分；D1、D2 的主体集中在 72-82 分，且左侧拖有低于 70 分的“长尾”，这部分学生正是后续异常检测和学业预警的关注对象。

4.4 成绩等级构成




按等级划分后，班级之间的差异更加直观：BD 班优秀率高达 87%（26/30），其余为良好；T1、T2 的良好与优秀合计约七成；D1、D2 以“中等”为主体（分别占 63%、59%），D1 仅 1 人达到优秀。各等级人数见表 4。

表 4 各班成绩等级人数分布

班级	优秀(≥ 85)	良好(80-85)	中等(70-80)	及格(60-70)	合计
D1	1	10	22	2	35
D2	5	8	20	1	34
BD	26	4	0	0	30
T1	12	15	13	0	40
T2	9	17	11	2	39

4.5 箱线图与异常值检测



箱线图 (box plot) 由五数概括 (最小值、Q1、中位数、Q3、最大值) 构成：箱体中线为中位数，箱体上下沿分别是 Q3 与 Q1，箱体覆盖了中间 50% 的学生；超出 $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ 范围的点被判定为异常点 (离群点)。


从图 4 可以读出：① BD 班箱体位置最高、高度最小，其最低分 (80.59) 已超过 D1、D2 两个班的中位数；② T1 与 T2 的中位数几乎相同 (81.66 与 81.96)，但 T2 下方出现两个异常点；③ 五个班共检测出 4 个异常点，全部为低分方向的异常，详见表 5。

表 5 箱线图规则检测出的异常学生

班级	学号	加权平均分	GPA	不及格门次	不及格学分	通过率	班内 Z 分数
D1	D45	61.93	1.43	4	11	60.7%	-2.93
D2	21D244	65.07	1.68	3	13	53.6%	-2.54
T2	21T248	67.68	1.76	2	10	60.0%	-2.67
T2	21T249	68.84	1.62	3	11	56.0%	-2.44

这 4 名学生均有 2-4 门课程不及格、学分通过率仅 54%-61%，班内 Z 分数均低于 -2.4，即成绩比本班平均水平低 2.4 个标准差以上。在教学管理场景中，这类异常点不是需要删除的“噪声”，而是最有价值的预警信号。

4.6 挂科情况




全体共有 24 名学生存在挂科，累计不及格 38 门次。其中 D1 班挂科率高达 40.0%（14/35 人），贡献了 21 门次，占全部不及格门次的 55%；BD 班无人挂科，T1 班仅 1 人挂 1 门。D2 与 T2 虽然平均分差距较大，但挂科率相近（14.7% 与 10.3%）。表 6 汇总了各班的其他关键指标。

表 6 各班其他关键指标

班级	平均 GPA	课程平均分	挂科人数	挂科率	不及格门次	人均不及格学 分	平均通过率
D1	2.57	81.20	14	40.0%	21	2.34	91.5%
D2	2.71	82.57	5	14.7%	8	1.12	96.0%
BD	3.61	88.70	0	0.0%	0	0.00	100.0%
T1	3.02	84.57	1	2.5%	1	0.12	99.5%
T2	2.95	83.72	4	10.3%	8	0.82	96.7%


4.7 Q-Q 图：平行班的分布对比



Q-Q 图把两个班相同分位数上的成绩配对画点：点落在 $y = x$ 上表示两班在该分位上成绩相同，点在上方表示纵轴班级更高。

- D1 vs D2：点基本位于 $y = x$ 上方，且越往高分端偏离越大，说明 D2 整体略好于 D1，主要差距在“尖子生”部分（D2 的高分段更高）；
- T1 vs T2：中间分位的点紧贴 $y = x$ ，两班中等水平学生几乎一致；但最低端的点明显落在下方，说明 T2 的差异主要来自少数低分学生——与箱线图中 T2 的两个异常点相互印证；
- T1 vs BD：所有点都在 $y = x$ 上方约 5–7 分，且斜率小于 1，说明 BD 在每个分位上都更高，同时分布更集中。

4.8 平行坐标图：多维画像



平行坐标图将每个班在 6 项指标上的均值（经 Min-Max 归一化）连成折线，可同时比较多个维度。BD 在所有“成绩类”指标上处于最高、在“挂科类”指标上处于最低；D1 正好相反；T1 在通过率和挂科指标上接近 BD，但在成绩指标上只处于中游——说明 T1 的特点是“少挂科但高分不多”，而 T2 与 D2 在挂科指标上处于中间。

五、班级差异的显著性检验

描述统计显示各班存在差异，但需要检验这种差异是否只是抽样误差造成的。Shapiro-Wilk 正态性检验显示五个班的 p 值均大于 0.05（最小为 0.105），Levene 方差齐性检验 $p = 0.155$ ，满足单因素方差分析（ANOVA）的前提。ANOVA 结果为 $F = 22.68$ ， $p < 0.001$ ；作为稳健性检验，非参数 Kruskal-Wallis 检验结果为 $H = 63.28$ ， $p < 0.001$ ，效应量 $\epsilon^2 = 0.34$ （属于大效应）。两种方法结论一致：五个班级的成绩存在显著差异。

进一步用 Mann-Whitney U 检验做两两比较，并用 Holm 方法校正多重比较带来的假阳性风险，结果见表 7。

表 7 班级两两比较结果（按 p 值排序）

班级对	中位数差	原始 p 值	Holm 校正 p 值	是否显著
D1 vs BD	-10.74	1.53e-10	1.53e-09	是
D2 vs BD	-9.28	2.10e-08	1.89e-07	是
BD vs T2	+5.97	7.42e-08	5.94e-07	是
BD vs T1	+6.27	4.29e-07	3.00e-06	是
D1 vs T1	-4.48	9.51e-05	5.70e-04	是
D1 vs T2	-4.78	8.21e-04	0.004	是
D2 vs T1	-3.01	0.008	0.033	是
D2 vs T2	-3.31	0.048	0.143	否
D1 vs D2	-1.47	0.267	0.534	否
T1 vs T2	-0.30	0.670	0.670	否

结论：① BD 与其余四个班均有显著差异；② D1 与 T1、T2 之间，D2 与 T1 之间差异显著；③ 平行班 D1 与 D2、T1 与 T2 之间差异不显著，D2 与 T2 在校正后也不显著。这表明班级之间的差异更多来自“专业/培养方案”层面，而不是同一专业内平行班之间的差异。

六、数据挖掘：主成分分析与聚类

描述性统计以“班级”为单位比较，但同一个班内部也存在不同类型的学生。本部分不预设分组，而是让算法从数据中自动发现学生群体，属于无监督学习。


6.1 主成分分析（PCA）降维

选取学分加权平均分、平均学分绩点、课程平均分、不及格门次、不及格学分、通过率 6 个指标，经 Z-score 标准化后进行 PCA。第一主成分（PC1）解释了 80.5% 的方差，6 个指标的载荷绝对值均约为 0.41，成绩类指标为正、挂科类指标为负，可解释为“综合学业水平”；第二主成分（PC2）解释了 17.8% 的方差，主要反映挂科情况中无法被平均分解释的部分。两个主成分合计解释 98.3% 的信息，即用 2 维即可近似表示原来的 6 维数据，这正是“维规约”的作用。

6.2 K-means 聚类

在标准化后的 6 维数据上运行 K-means（每个 k 使用 50 组随机初始中心，取误差平方和最小的结果），用肘部法和轮廓系数选择聚类数 k（图 9）。k = 2 时轮廓系数最高（0.68），但此时只是把“有挂科”与“无挂科”的学生分开，仅凭“不及格门次”一个字段就能得到，信息量有限；k = 3 处 SSE 曲线出现明显拐点（由 439 降至 234），轮廓系数 $0.52 > 0.5$ ，聚类结构合理，并能把未挂科学生进一步分为高分与中等两类，更有管理意义。因此选择 k = 3。

图9 K-means 聚类数 k 的选择






图 10 将聚类结果投影到前两个主成分上。没有挂科的学生（A、B 两组）几乎落在一条直线上，说明他们之间只有分数高低的差别；有挂科的学生（C 组）明显偏离这条直线并分散在左侧，说明“是否挂科”提供了平均分之外的独立信息。

表 8 三个聚类的特征画像（各指标均值）

聚类	人数	加权平均分	GPA	不及格门次	不及格学分	通过率
A 学业优良组	73	86.68	3.50	0.00	0.00	100.0%
B 稳定中等组	83	78.94	2.72	0.02	0.05	99.8%
C 学业预警组	22	71.65	2.05	1.64	6.95	74.3%

- A 学业优良组（73 人）：平均分 86.68，无人挂科，加权平均分范围 82.3–92.2；
- B 稳定中等组（83 人）：平均分 78.94，基本无挂科（仅 2 人各挂 1 门），是人数最多的群体；
- C 学业预警组（22 人）：平均分 71.65，人均不及格 1.6 门次，平均通过率仅 74.3%。

图11 各班学生在三个聚类中的分布




图 11 显示了各班学生在三个群体中的分布：BD 班 27/30 人属于优良组，没有预警学生；D1 班有 12 人（占全班 34%）属于预警组，占全部预警学生的 55%；T1、T2 的优良组人数相同（各 17 人），但 T2 有 4 名预警学生，T1 只有 1 名。

图12 不及格门次与学分加权平均分 ($r = -0.64$)




图 12 从另一个角度验证了聚类结果：不及格门次与学分加权平均分呈中度负相关 ($r = -0.64$)，且挂科门次越多，平均分越低；聚类的分界与“是否挂科”以及 82–83 分附近的分数线高度吻合，结果具有良好的可解释性。

6.3 学业预警名单

根据聚类结果，C 组学生即为需要重点关注的学业预警对象，名单见表 9（按加权平均分升序）。其中 D45、21D244、21T248、21T249 共 4 人同时也是箱线图检测出的异常点，属于最高优先级。

表 9 学业预警学生名单 (C 组)

序号	班级	学号	加权平均分	GPA	不及格门次	不及格学分	通过率
1	D1	D45	61.93	1.43	4	11	60.7%
2	D2	21D244	65.07	1.68	3	13	53.6%
3	D1	D44	66.71	1.88	2	10	64.3%
4	T2	21T248	67.68	1.76	2	10	60.0%
5	T2	21T249	68.84	1.62	3	11	56.0%
6	D1	D42	70.00	1.96	1	5	82.1%
7	D1	D43	70.04	2.02	2	10	64.3%
8	T1	21T150	70.16	1.82	1	5	80.0%
9	D2	21D242	71.14	2.00	1	5	82.1%
10	D2	21D241	72.43	2.02	1	5	82.1%
11	D1	D40	72.68	2.11	1	3	89.3%
12	D2	21D239	72.82	2.02	2	10	64.3%
13	D2	21D240	73.00	2.18	1	5	82.1%
14	D1	D41	73.11	2.13	2	6	78.6%
15	D1	D31	73.54	2.20	2	10	64.3%
16	D1	D39	73.61	2.14	1	3	89.3%
17	T2	21T247	73.80	2.14	2	6	76.0%
18	D1	D34	74.64	2.25	1	5	82.1%
19	D1	D26	75.58	2.38	1	5	79.2%
20	D1	D30	75.64	2.41	1	5	82.1%
21	T2	21T237	76.16	2.38	1	5	80.0%
22	D1	D25	77.64	2.54	1	5	82.1%

七、结论与建议

7.1 主要结论

- 数据质量：原始数据完整、无重复，业务规则全部成立，但存在文本型数值、格式不统一、量纲不一致等问题；经清洗、集成、变换后得到 178×23 的分析数据集。“总分”受修读门数影响，不宜直接用于比较。
- 班级排名：BD > T1 ≈ T2 > D2 ≈ D1，班级间差异显著 ($p < 0.001$ ，大效应)。BD 班“高而集中”，平均分 87.67、标准差 3.15、优秀率 87%、零挂科，是五个班中表现最好的班级。
- 风险集中：D1 班平均分最低、挂科率最高 (40.0%)，一个班贡献了 55% 的不及格门次和 55% 的预警学生，是需要重点干预的班级。
- 平行班差异小：D1 与 D2、T1 与 T2 之间差异不显著，班级间的主要差距来自专业/培养方案层面；T2 的劣势主要集中在少数低分学生。
- 群体结构：聚类把学生分为优良 (73 人)、中等 (83 人)、预警 (22 人) 三类，“是否挂科”是区分预警群体的关键特征。

7.2 建议

- 分层干预：对 C 组 22 名预警学生 (尤其是 4 名异常点学生) 开展一对一学业谈话，制定补考与重修计划；对 B 组学生以提升为主，鼓励其向 A 组靠拢；

- 聚焦 D1 班：结合课程层面的成绩明细，找出 D1 挂科集中的课程，判断是课程难度、教学安排还是学习投入的问题，有针对性地开设辅导；
- 经验共享：总结 BD 班的学风建设与学习方法经验，在 D 类班级中推广；
- 常态化监测：将本文的预处理与聚类流程固化为每学期的学业预警机制，及早发现风险学生。

八、局限性说明

- 课程不同导致可比性有限：D、BD、T 三类班级的应修学分和课程门数不同，可能修读不同的课程、由不同教师评分，跨专业比较平均分会受课程难度和评分尺度的影响，结论应解读为“相对表现”；
- 缺少课程级明细：数据只有学期汇总指标，无法定位具体是哪些课程挂科，也无法区分修读门数偏少的学生是免修、缓考还是其他原因（共 8 人，建议向教务核实）；
- 样本量与时间跨度：每班仅 30–40 人、只有一个学期的数据，聚类结果和预警名单需结合后续学期数据持续验证。

九、工具与 AI 使用说明

根据课程对 AI 使用伦理与学术规范的要求，现将本报告使用的工具及 AI 参与情况说明如下：

- 分析工具：Python 3（pandas 数据处理，SciPy 统计检验，NumPy 实现 PCA 与 K-means，Matplotlib 绘图）；Excel（数据查看及描述统计复核）；
- AI 参与部分：本报告的数据处理与绘图代码（见附录）及报告文字初稿由 AI 工具 Claude（Anthropic）协助生成；
- 本人完成部分：**【提交前请本人如实填写：例如“本人在本地 Python 环境中运行了全部代码，并用 Excel“数据分析→描述统计”复核了表 3 中各班的均值、标准差等结果，二者一致；本人对第×节的结论和建议进行了修改补充”】**

所有统计结果均由代码在真实数据上运行得到，未经人工改动；AI 生成的内容已经过核对，对其中的错误本人承担责任。

附录 分析代码

以下为完整分析代码（Python 3，依赖 pandas、numpy、scipy、matplotlib、openpyxl）。运行方式：
python analysis.py 成绩数据.xlsx 输出目录。

```
"""五个班级成绩数据：预处理 + 描述性统计 + 可视化 + 数据挖掘（聚类/异常检测）
运行：python analysis.py <xlsx 路径> <输出目录>
"""

import sys, json, warnings
import numpy as np, pandas as pd
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib import font_manager
from scipy import stats
warnings.filterwarnings("ignore")

SRC, OUT = sys.argv[1], sys.argv[2]
FIG = f"{OUT}/fig"

# ----- 绘图风格 -----
font_manager.fontManager.addfont("/usr/share/fonts/truetype/wqy/wqy-zenhei.ttc")
plt.rcParams.update({
    "font.family": "WenQuanYi Zen Hei", "axes.unicode_minus": False,
    "font.size": 10, "axes.titlesize": 12, "axes.titleweight": "bold",
    "axes.edgecolor": "#b8b7b2", "axes.labelcolor": "#52514e",
    "xtick.color": "#52514e", "ytick.color": "#52514e",
    "axes.spines.top": False, "axes.spines.right": False,
    "axes.grid": True, "grid.color": "#e6e5e0", "grid.linewidth": 0.6,
    "axes.axisbelow": True, "figure.facecolor": "white", "savefig.dpi": 200,
    "legend.frameon": False,
})
INK, INK2, MUTED = "#0b0b0b", "#52514e", "#8a8984"
CLASSES = ["D1", "D2", "BD", "T1", "T2"]
CCOL = dict(zip(CLASSES, ["#2a78d6", "#eb6834", "#1baf7a", "#eda100", "#e87ba4"]))
LEVELS = ["及格(60-70)", "中等(70-80)", "良好(80-85)", "优秀(≥85)"]
LCOL = ["#86b6ef", "#3987e5", "#256abf", "#104281"] # 有序单色蓝阶
KCOL = ["#2a78d6", "#eb6834", "#1baf7a"]

def save(fig, name):
    fig.savefig(f"{FIG}/{name}.png", bbox_inches="tight"); plt.close(fig)

# ----- 1. 数据读取与审查 -----
raw = pd.read_excel(SRC, sheet_name=None, dtype=str)
import openpyxl
_wb = openpyxl.load_workbook(SRC)
TEXT_CELLS = {ws.title: sum(isinstance(c.value, str) for r in ws.iter_rows(min_row=2, min_col=2) for c in r) for ws in _wb}
audit = []
frames = []
for cls, df in raw.items():
    first_col = df.columns[0]
    text_cells = TEXT_CELLS[cls] # 以文本格式存储的数值单元格（Excel 中带绿色小三角）
    pr_fmt = "百分号文本(如 82.14%)" if df["通过率"].str.contains("%").any() else "小数文本(如 0.8)"
    df = df.rename(columns={first_col: "ID"})
    d = df.copy()
    d["通过率"] = d["通过率"].str.rstrip("%").astype(float)
    if d["通过率"].max() > 1.5:
        d["通过率"] /= 100
    for c in d.columns[1:]:
        d[c] = pd.to_numeric(d[c], errors="coerce")
    audit.append(dict(
        班级=cls, 样本数=len(d), 首列列名=first_col, 学号示例=df.ID.iloc[0], 通过率格式=pr_fmt,
        文本型数值单元格=text_cells, 缺失值=int(d.isna().sum().sum()),
        重复学号=int(d.ID.duplicated().sum()), 重复记录=int(d.duplicated().sum()),
        学分恒等式不符=int((d["获得学分"] + d["不及格学分"] != d["总学分"]).sum()),
        通过率口径不符=int((abs(d["获得学分"] / d["总学分"] - d["通过率"]) > 0.006).sum()),
        越界值=int(((d["学分加权平均分"] < 0) | (d["学分加权平均分"] > 100) |
            (d["平均学分绩点"] < 0) | (d["平均学分绩点"] > 5) |
            (d["通过率"] < 0) | (d["通过率"] > 1)).sum()),
        标准总学分=int(d["总学分"].mode()[0]), 标准门数=int(d["门数"].mode()[0]),
        总学分非标准人数=int((d["总学分"] != d["总学分"].mode()[0]).sum()),
    ))
    d.insert(0, "班级", cls)
    frames.append(d)
audit = pd.DataFrame(audit)
```

```

# ----- 2. 数据集成与变换 -----
data = pd.concat(frames, ignore_index=True) # 集成: 5 表纵向合并
data["课程平均分"] = data["总分"] / data["门数"] # 消除门数不同带来的量纲差异
data["是否挂科"] = (data["不及格门次"] > 0).astype(int)
data["成绩等级"] = pd.cut(data["学分加权平均分"], [60, 70, 80, 85, 100.01],
                           labels=LEVELS, right=False)
for c in ["学分加权平均分", "总分", "课程平均分"]:
    data[f"{c}_MinMax"] = (data[c] - data[c].min()) / (data[c].max() - data[c].min())
    data[f"{c}_Z"] = (data[c] - data[c].mean()) / data[c].std()
data["班内 Z 分数"] = data.groupby("班级")["学分加权平均分"].transform(lambda s: (s - s.mean()) / s.std())

# ----- 3. 描述性统计 -----
def describe(s):
    m = s.mode()
    mode = "无 (各值不重复)" if (s.value_counts().max() == 1) else " ".join(f"{v:.2f}" for v in
m[:3])
    q1, q3 = s.quantile(.25), s.quantile(.75)
    return dict(样本数=len(s), 均值=s.mean(), 中位数=s.median(), 众数=mode,
                标准差=s.std(), 方差=s.var(), 最小值=s.min(), 最大值=s.max(), 极差=s.max() - s.min(),
                Q1=q1, Q3=q3, IQR=q3 - q1, 变异系数=s.std() / s.mean(),
                偏度=s.skew(), 峰度=s.kurt())
g = data.groupby("班级", sort=False)
desc = pd.DataFrame({c: describe(g.get_group(c)["学分加权平均分"]) for c in CLASSES}).T
desc_all = describe(data["学分加权平均分"])

other = pd.DataFrame({
    "平均学分绩点(均值)": g["平均学分绩点"].mean(),
    "课程平均分(均值)": g["课程平均分"].mean(),
    "挂科人数": g["是否挂科"].sum(),
    "挂科率": g["是否挂科"].mean(),
    "不及格门次合计": g["不及格门次"].sum(),
    "人均不及格学分": g["不及格学分"].mean(),
    "通过率(均值)": g["通过率"].mean(),
    "标准总学分": g["总学分"].agg(lambda s: s.mode()[0]),
    "标准门数": g["门数"].agg(lambda s: s.mode()[0]),
}).loc[CLASSES]
level_ct = pd.crosstab(data["班级"], data["成绩等级"]).loc[CLASSES, LEVELS]
level_pct = level_ct.div(level_ct.sum(1), axis=0)

# ----- 4. 差异检验 -----
groups = [g.get_group(c)["学分加权平均分"] for c in CLASSES]
shapiro = {c: stats.shapiro(s).pvalue for c, s in zip(CLASSES, groups)}
levene = stats.levene(*groups).pvalue
anova = stats.f_oneway(*groups)
kw = stats.kruskal(*groups)
eps2 = (kw.statistic - len(groups) + 1) / (len(data) - len(groups)) # Kruskal-Wallis 效应量  $\epsilon^2$ 
pairs = []
for i in range(5):
    for j in range(i + 1, 5):
        u = stats.mannwhitneyu(groups[i], groups[j], alternative="two-sided")
        pairs.append([CLASSES[i], CLASSES[j], groups[i].median() - groups[j].median(), u.pvalue])
pairs = pd.DataFrame(pairs, columns=["班级 A", "班级 B", "中位数差(A-B)", "p 值"]).sort_values("p 值")
m = len(pairs) # Holm 校正
adj, running = [], 0
for k, p in enumerate(pairs["p 值"]):
    running = max(running, min(1, p * (m - k))); adj.append(running)
pairs["Holm 校正 p 值"] = adj
pairs["显著( $\alpha=0.05$ )"] = np.where(pairs["Holm 校正 p 值"] < .05, "是", "否")

# ----- 5. 异常检测 (箱线图 1.5×IQR 规则, 班内) -----
def iqr_flags(s):
    q1, q3 = s.quantile(.25), s.quantile(.75); r = q3 - q1
    return (s < q1 - 1.5 * r) | (s > q3 + 1.5 * r), q1 - 1.5 * r
data["箱线图异常"] = False
fences = {}
for c in CLASSES:
    idx = data["班级"] == c
    f, lo = iqr_flags(data.loc[idx, "学分加权平均分"])
    data.loc[idx, "箱线图异常"] = f; fences[c] = lo
outliers = data[data["箱线图异常"]][["班级", "ID", "学分加权平均分", "平均学分绩点", "不及格门次", "不及格学
分", "通过率", "班内 Z 分数"]]

# ----- 6. 相关分析 (冗余检测) -----
num_cols = ["学分加权平均分", "平均学分绩点", "课程平均分", "总分", "获得学分", "不及格学分", "不及格门次", "通
过率"]
corr = data[num_cols].corr()

```

```

# ----- 7. 数据挖掘: PCA 降维 + K-means 聚类 -----
feat = ["学分加权平均分", "平均学分绩点", "课程平均分", "不及格门次", "不及格学分", "通过率"]
X = data[feat].values
Xz = (X - X.mean(0)) / X.std(0, ddof=0)
evals, evects = np.linalg.eigh(np.cov(Xz, rowvar=False))
order = evals.argsort()[::-1]; evals, evects = evals[order], evects[:, order]
if evects[0, 0] < 0: evects[:, 0] *= -1
if evects[3, 1] < 0: evects[:, 1] *= -1
pcs = Xz @ evects[:, :2]
expl = evals / evals.sum()
loadings = pd.DataFrame(evects[:, :2], index=feat, columns=["PC1", "PC2"])

def kmeans(Z, k, seeds=50):
    best = None
    for sd in range(seeds):
        rng = np.random.default_rng(sd)
        C = Z[rng.choice(len(Z), k, replace=False)]
        for _ in range(300):
            lab = ((Z[:, None] - C) ** 2).sum(-1).argmin(1)
            newC = np.array([Z[lab == j].mean(0) if (lab == j).any() else C[j] for j in range(k)])
            if np.allclose(newC, C): break
            C = newC
            sse = ((Z - C[lab]) ** 2).sum()
            if best is None or sse < best[0]: best = (sse, lab, C)
    return best

def silhouette(Z, lab):
    D = np.sqrt(((Z[:, None] - Z[None]) ** 2).sum(-1)); s = []
    for i in range(len(Z)):
        same = lab == lab[i]; a = D[i, same & (np.arange(len(Z)) != i)].mean() if same.sum() > 1
    else 0
        b = min(D[i, lab == j].mean() for j in set(lab) if j != lab[i]); s.append((b - a) / max(a, b))
    return float(np.mean(s))

kscan = []
for k in range(2, 7):
    sse, lab, _ = kmeans(Xz, k); kscan.append(dict(k=k, SSE=sse, 轮廓系数=silhouette(Xz, lab)))
kscan = pd.DataFrame(kscan)
K = 3
_, lab, _ = kmeans(Xz, K)
# 按加权平均分高低给簇命名
rank = pd.Series(lab).map(data.groupby(lab)["学分加权平均分"].mean().rank(ascending=False).astype(int))
names = {1: "A 学业优良组", 2: "B 稳定中等组", 3: "C 学业预警组"}
data["聚类"] = rank.map(names).values
cl_profile = data.groupby("聚类")[["学分加权平均分", "平均学分绩点", "不及格门次", "不及格学分", "通过率"]].mean()
cl_profile.insert(0, "人数", data.groupby("聚类").size())
cl_cross = pd.crosstab(data["班级"], data["聚类"]).loc[CLASSES]
warn_list = data[data["聚类"] == names[3]][["班级", "ID", "学分加权平均分", "平均学分绩点", "不及格门次", "不及格学分", "通过率"]].sort_values("学分加权平均分")

# ===== 图表 =====
x = np.arange(5)
# 图1 各班加权平均分均值 + 95%CI
means = desc["均值"].astype(float); sd = desc["标准差"].astype(float); n = desc["样本数"].astype(int)
ci = stats.t.ppf(.975, n - 1) * sd / np.sqrt(n)
fig, ax = plt.subplots(figsize=(7, 3.8))
ax.bar(x, means - 60, bottom=60, width=.56, color=[CCOL[c] for c in CLASSES], edgecolor="white", linewidth=2)
ax.errorbar(x, means, yerr=ci, fmt="none", ecolor=INK2, elinewidth=1.2, capsize=5)
for i, c in enumerate(CLASSES):
    ax.text(i, means[c] + ci[c] + .4, f"{means[c]:.2f}", ha="center", va="bottom", color=INK,
            fontsize=10, fontweight="bold")
ax.axhline(desc_all["均值"], color=MUTED, ls="--", lw=1)
ax.set_xlim(-.5, 5.15)
ax.text(4.35, desc_all["均值"], f"全体均值\n{desc_all['均值']:.2f}", ha="left", va="center",
        color=INK2, fontsize=9)
ax.set_xticks(x, [f"{c}\n(n={n[c]})" for c in CLASSES]); ax.set_ylim(60, 92); ax.set_ylabel("学分加权平均分")
ax.set_title("图1 各班学分加权平均分均值 (误差线为95%置信区间)", loc="left"); ax.grid(axis="x", visible=False)
save(fig, "fig1_mean_bar")

# 图2 直方图小多图
bins = np.arange(60, 95.1, 2.5)
fig, axes = plt.subplots(1, 5, figsize=(12, 3), sharey=True, sharex=True)
for ax, c in zip(axes, CLASSES):
    s = g.get_group(c)["学分加权平均分"]
    ax.hist(s, bins=bins, color=CCOL[c], edgecolor="white", linewidth=1.5)

```

```

    ax.axvline(s.mean(), color=INK, lw=1.2); ax.axvline(s.median(), color=INK, lw=1.2, ls=":")
    ax.set_title(f"{c} 偏度 {s.skew():+.2f}", fontsize=10.5); ax.set_xlabel("加权平均分")
    ax.grid(axis="x", visible=False)
axes[0].set_ylabel("人数")
fig.suptitle("图2 各班学分加权平均分分布直方图 (实线=均值, 虚线=中位数, 组距2.5分)", x=0.01, ha="left",
fontweight="bold", fontsize=12)
fig.tight_layout(); save(fig, "fig2_hist")

# 图3 成绩等级百分比堆叠条形图
fig, ax = plt.subplots(figsize=(8, 3.8))
left = np.zeros(5)
for lv, col in zip(LEVELS, LCOL):
    v = level_pct[lv].values
    ax.barh(x, v, left=left, color=col, edgecolor="white", linewidth=2, height=.62, label=lv)
    for i, (l, w) in enumerate(zip(left, v)):
        if w >= .07:
            ax.text(l + w / 2, i, f"{w:.0%}", ha="center", va="center", fontsize=9,
                    color="white" if col != LCOL[0] else INK)
    left += v
ax.set_yticks(x, CLASSES); ax.invert_yaxis(); ax.set_xlim(0, 1)
ax.xaxis.set_major_formatter(matplotlib.ticker.PercentFormatter(1.0))
ax.legend(ncol=4, loc="lower center", bbox_to_anchor=(.5, 1.0), fontsize=9)
ax.set_title("图3 各班成绩等级构成 (按学分加权平均分划分)", loc="left", pad=28); ax.grid(axis="y",
visible=False)
save(fig, "fig3_levels")

# 图4 箱线图 + 散点 + 异常点标注
fig, ax = plt.subplots(figsize=(8, 4.6))
bp = ax.boxplot(groups, positions=x, widths=.5, patch_artist=True, showfliers=False,
                medianprops=dict(color=INK, lw=1.6), whiskerprops=dict(color=INK2),
                capprops=dict(color=INK2),
                boxprops=dict(linewidth=1, edgecolor=INK2))
for patch, c in zip(bp["boxes"], CLASSES):
    patch.set_facecolor(CCOL[c]); patch.set_alpha(.35)
rng = np.random.default_rng(0)
for i, c in enumerate(CLASSES):
    d = data[data["班级"] == c]
    jit = rng.uniform(-.13, .13, len(d))
    normal = ~d["箱线图异常"]
    ax.scatter(i + jit[normal], d["学分加权平均分"][normal], s=14, color=CCOL[c], edgecolor="white",
linewidth=6, zorder=3)
    ax.scatter(i + jit[~normal], d["学分加权平均分"][~normal], s=60, facecolor="white",
edgecolor="#e34948", linewidth=2, zorder=4)
    for (_, r), jj in zip(d[~normal].iterrows(), jit[~normal]):
        ax.annotate(f"{r.ID} ({r.学分加权平均分:.2f})", (i + jj, r.学分加权平均分), xytext=(10, -3),
                    textcoords="offset points", fontsize=8.5, color=INK2)
ax.set_xticks(x, CLASSES); ax.set_ylabel("学分加权平均分"); ax.grid(axis="x", visible=False)
ax.set_title("图4 各班成绩箱线图 (红圈=超出 Q1-1.5×IQR 的异常点)", loc="left")
save(fig, "fig4_box")

# 图5 挂科情况
fig, ax = plt.subplots(figsize=(7, 3.6))
fr = other["挂科率"]
ax.bar(x, fr, width=.56, color=[CCOL[c] for c in CLASSES], edgecolor="white", linewidth=2)
for i, c in enumerate(CLASSES):
    ax.text(i, fr[c] + .008, f"{fr[c]:.1%}\n{int(other.loc[c, '挂科人数'])}/{int(n[c])}人,
{int(other.loc[c, '不及格门次合计'])}门次",
            ha="center", va="bottom", fontsize=8.8, color=INK)
ax.set_xticks(x, CLASSES); ax.set_ylim(0, .5);
ax.yaxis.set_major_formatter(matplotlib.ticker.PercentFormatter(1.0))
ax.set_ylabel("有挂科学生占比"); ax.grid(axis="x", visible=False)
ax.set_title("图5 各班挂科率 (至少1门不及格的学生占比)", loc="left")
save(fig, "fig5_fail")

# 图6 相关系数热力图
from matplotlib.colors import LinearSegmentedColormap
div = LinearSegmentedColormap.from_list("div", ["#e34948", "#f0efec", "#2a78d6"])
fig, ax = plt.subplots(figsize=(6.6, 5.4))
im = ax.imshow(corr.values, cmap=div, vmin=-1, vmax=1)
ax.set_xticks(range(len(num_cols)), num_cols, rotation=40, ha="right");
ax.set_yticks(range(len(num_cols)), num_cols)
for i in range(len(num_cols)):
    for j in range(len(num_cols)):
        v = corr.values[i, j]; ax.text(j, i, f"{v:.2f}", ha="center", va="center", fontsize=8,
            color="white" if abs(v) > .75 else INK)
ax.grid(False); ax.spines[:].set_visible(False)
fig.colorbar(im, ax=ax, shrink=.75, label="Pearson 相关系数")
ax.set_title("图6 各数值属性相关系数矩阵 (全体 178 人)", loc="left")
save(fig, "fig6_corr")

```

```

# 图7 QQ 图：同专业两班对比
def qq(ax, a, b, ca, cb):
    qs = np.linspace(.02, .98, 25)
    qa, qb = np.quantile(g.get_group(a)["学分加权平均分"], qs), np.quantile(g.get_group(b)["学分加权平均分"], qs)
    lo, hi = 60, 93
    ax.plot([lo, hi], [lo, hi], color=MUTED, ls="--", lw=1)
    ax.scatter(qa, qb, s=26, color=CCOL[b], edgecolor="white", linewidth=.8, zorder=3)
    mid = np.quantile(g.get_group(a)["学分加权平均分"], .5), np.quantile(g.get_group(b)["学分加权平均分"], .5)
    ax.scatter(*mid, s=70, facecolor="none", edgecolor=INK, lw=1.4, zorder=4)
    ax.annotate("中位数", mid, xytext=(8, -14), textcoords="offset points", fontsize=8.5, color=INK2)
    ax.text(lo + 1, hi - 1.5, "y = x", color=MUTED, fontsize=8.5)
    ax.set_xlim(lo, hi); ax.set_ylim(lo, hi); ax.set_aspect("equal")
    ax.set_xlabel(f"{a} 班分位数"); ax.set_ylabel(f"{b} 班分位数")
fig, axes = plt.subplots(1, 3, figsize=(12, 4.2))
for ax, (a, b) in zip(axes, [("D1", "D2"), ("T1", "T2"), ("T1", "BD")]):
    qq(ax, a, b, CCOL[a], CCOL[b]); ax.set_title(f"{a} vs {b}", fontsize=11)
fig.suptitle("图7 分位数-分位数图 (Q-Q plot) : 点在 y=x 上方表示纵轴班级在该分位上成绩更高", x=.01, ha="left", fontweight="bold", fontsize=12)
fig.tight_layout(); save(fig, "fig7_qq")

# 图8 平行坐标图：各班均值画像 (Min-Max 归一化)
pc_cols = ["学分加权平均分", "平均学分绩点", "课程平均分", "通过率", "不及格门次", "不及格学分"]
pm = data.groupby("班级")[pc_cols].mean().loc[CLASSES]
pmn = (pm - pm.min()) / (pm.max() - pm.min())
fig, ax = plt.subplots(figsize=(9, 4.2))
for c in CLASSES:
    ax.plot(range(len(pc_cols)), pmn.loc[c], color=CCOL[c], lw=2, marker="o", ms=8, mec="white", mew=1.5)
    ax.text(len(pc_cols) - 1 + .12, pmn.loc[c].iloc[-1], c, color=INK, va="center", fontsize=9.5, fontweight="bold")
# 末端标签避让
ax.set_xticks(range(len(pc_cols)), pc_cols); ax.set_xlim(-.2, len(pc_cols) - .5)
ax.set_ylabel("Min-Max 归一化值 (0=五班最低, 1=五班最高)"); ax.grid(axis="y", visible=False)
for i in range(len(pc_cols)): ax.axvline(i, color="#d8d7d2", lw=1, zorder=0)
ax.legend([plt.Line2D([], [], color=CCOL[c], lw=2, marker="o") for c in CLASSES], CLASSES, ncol=5, loc="lower center", bbox_to_anchor=(.5, 1.0))
ax.set_title("图8 平行坐标图：五个班级的多维均值画像", loc="left", pad=26)
save(fig, "fig8_parallel")

# 图9 K 值选择
fig, ax1 = plt.subplots(1, 2, figsize=(9, 3.2))
ax1[0].plot(kscan.k, kscan.SSE, color=KCOL[0], lw=2, marker="o", ms=8, mec="white");
ax1[0].set_title("肘部法：簇内误差平方和 SSE", fontsize=10.5); ax1[0].set_xlabel("k")
ax1[1].plot(kscan.k, kscan["轮廓系数"], color=KCOL[0], lw=2, marker="o", ms=8, mec="white");
ax1[1].set_title("轮廓系数 (越大越好)", fontsize=10.5); ax1[1].set_xlabel("k")
for a in ax1: a.axvline(K, color=MUTED, ls="--", lw=1); a.set_xticks(range(2, 7))
fig.suptitle("图9 K-means 聚类数 k 的选择", x=.01, ha="left", fontweight="bold", fontsize=12)
fig.tight_layout(); save(fig, "fig9_kscan")

# 图10 PCA 二维聚类散点
fig, ax = plt.subplots(figsize=(8, 4.8))
for j, nm in enumerate(sorted(names.values())):
    idx = (data["聚类"] == nm).values
    ax.scatter(pcs[idx, 0], pcs[idx, 1], s=40, color=KCOL[j], edgecolor="white", linewidth=1, label=f"{nm} ({idx.sum()}人)", zorder=3)
ax.legend(loc="lower left")
ax.set_xlabel(f"PC1：综合学业水平 (解释方差 {expl[0]:.1%})"); ax.set_ylabel(f"PC2 (解释方差 {expl[1]:.1%})")
ax.set_title("图10 PCA 降维后的 K-means 聚类结果 (k=3)", loc="left")
save(fig, "fig10_cluster")

# 图11 聚类×班级构成
fig, ax = plt.subplots(figsize=(8, 3.6))
cp = cl_cross.div(cl_cross.sum(1), axis=0); left = np.zeros(5)
for j, nm in enumerate(sorted(names.values())):
    v = cp[nm].values
    ax.barh(x, v, left=left, color=KCOL[j], edgecolor="white", linewidth=2, height=.62, label=nm)
    for i, (l, w) in enumerate(zip(left, v)):
        if w >= .06: ax.text(l + w / 2, i, f"{int(cl_cross.loc[CLASSES[i], nm])}人", ha="center", va="center", fontsize=9, color="white" if j != 2 else INK)
        left += v
ax.set_yticks(x, CLASSES); ax.invert_yaxis(); ax.set_xlim(0, 1)
ax.xaxis.set_major_formatter(matplotlib.ticker.PercentFormatter(1.0)); ax.grid(axis="y", visible=False)
ax.legend(ncol=3, loc="lower center", bbox_to_anchor=(.5, 1.0), fontsize=9)
ax.set_title("图11 各班学生在三个聚类中的分布", loc="left", pad=28)

```

```

save(fig, "fig11_cluster_by_class")

# 图 12 不及格门次 vs 加权平均分 (按聚类着色)
fig, ax = plt.subplots(figsize=(7.5, 4.2))
jit = rng.uniform(-.12, .12, len(data))
for j, nm in enumerate(sorted(names.values())):
    idx = (data["聚类"] == nm).values
    ax.scatter(data["不及格门次"][idx] + jit[idx], data["学分加权平均分"][idx], s=36, color=KC0L[j],
edgecolor="white", linewidth=1, label=nm, zorder=3)
r = data["不及格门次"].corr(data["学分加权平均分"])
ax.set_xticks(range(5)); ax.set_xlabel("不及格门次"); ax.set_ylabel("学分加权平均分");
ax.legend(loc="upper right")
ax.set_title(f"图 12 不及格门次与学分加权平均分 (r = {r:.2f}) ", loc="left")
save(fig, "fig12_scatter")

# ===== 导出 =====
with pd.ExcelWriter(f"{OUT}/成绩数据_清洗后及分析结果.xlsx") as w:
    data.to_excel(w, sheet_name="清洗集成后数据", index=False)
    audit.to_excel(w, sheet_name="数据质量审查", index=False)
    desc.to_excel(w, sheet_name="描述统计_加权平均分")
    other.to_excel(w, sheet_name="其他指标")
    level_ct.to_excel(w, sheet_name="成绩等级人数")
    pairs.to_excel(w, sheet_name="两两比较", index=False)
    outliers.to_excel(w, sheet_name="异常点", index=False)
    corr.to_excel(w, sheet_name="相关系数")
    cl_profile.to_excel(w, sheet_name="聚类画像")
    cl_cross.to_excel(w, sheet_name="聚类×班级")
    warn_list.to_excel(w, sheet_name="学业预警名单", index=False)

res = dict(
    audit=audit.to_dict("records"), desc=desc.astype(object).to_dict("index"), desc_all=desc_all,
    other=other.to_dict("index"), level_ct=level_ct.to_dict("index"),
    level_pct=level_pct.to_dict("index"),
    shapiro=shapiro, levene=levene, anova=[anova.statistic, anova.pvalue], kw=[kw.statistic,
kw.pvalue], eps2=eps2,
    pairs=pairs.to_dict("records"), outliers=outliers.to_dict("records"), fences=fences,
    corr=corr.round(3).to_dict(), expl=expl.tolist(), loadings=loadings.to_dict("index"),
    kscan=kscan.to_dict("records"), cl_profile=cl_profile.to_dict("index"),
    cl_cross=cl_cross.to_dict("index"),
    warn_list=warn_list.to_dict("records"), N=len(data),
    nonstd=data[(data["门数"] != data.groupby("班级")["门数"].transform(lambda s: s.mode()[0]))][["班
级", "ID", "总学分", "门数", "总分", "课程平均分"]].to_dict("records"),
    rank_total_vs_wavg=dict(spearman=data["总分"].corr(data["学分加权平均分"], method="spearman"),
    avg=data["课程平均分"].corr(data["学分加权平均分"])),
)
json.dump(res, open(f"{OUT}/results.json", "w"), ensure_ascii=False, indent=1, default=float)
print("done")

```